

AgroBiome

Plataforma de Caracterização de Solos de Vinha através da Inferência de Traços Funcionais do Microbioma

Memória Descritiva — Viticultura

AppGenomics, Lda · Vouchers para Startups (PRR / IAPMEI)

Junho de 2026



Table of Contents

Sumário executivo	3
1. Enquadramento e objetivos	3
1.1. Contexto	3
1.2. Objetivos.....	3
2. Dados de base	4
2.1. Amostras de microbioma (input)	4
2.2. Base referência de traços funcionais.....	4
3. Arquitetura e metodologia	5
3.1. Processamento taxonómico e normalização.....	5
3.1.1. Identidade e rastreio das amostras.....	5
3.2. Anotação de traços — reprodução local do <i>sumTraits</i>	5
3.3. Matriz de composição	6
3.4. Diversidade beta e ordenação.....	6
3.5. Comparação e inferência do perfil funcional	6
4. Camada interpretativa	6
4.1. Princípios	6
4.2. Estrutura de grupos funcionais.....	7
4.3. Réguas relativas e escalas absolutas	7
4.4. Exemplos de leitura	7
5. Plataforma.....	8
5.1. Descrição funcional.....	8
5.2. Características técnicas	9
6. Validação e controlo de qualidade.....	9
8. Conclusão	10
Anexo A — Indicadores quantitativos do piloto.....	11
A.1. Base de dados de referência.....	11
A.2. Diversidade beta e ordenação	11
A.3. Validação numérica	11

Sumário executivo

A presente memória descreve o trabalho técnico desenvolvido pela AppGenomics no âmbito do projeto **Vouchers para Startups (PRR / IAPMEI)**, consubstanciado numa **plataforma de inferência de traços funcionais do microbioma do solo** a partir de perfis taxonômicos obtidos por sequenciação genética (gene 16S rRNA). O caso de uso é a **viticultura**.

O sistema constrói uma **base de dados de referência** de amostras de microbioma de solo — agregadas de múltiplos projetos públicos de sequenciação e de amostras próprias, com aplicação-piloto em viticultura —, anota cada amostra com **traços fenotípicos** (potencial funcional da comunidade microbiana) e permite **comparar uma amostra nova** contra essa base, inferindo o seu perfil funcional por proximidade composicional. O resultado é apresentado numa **plataforma web de página única**, sem servidor, concebida para servir de evidência demonstrável e publicável.

O entregável distingue-se por três decisões metodológicas centrais:

1. **Reprodução local e auditável** do fluxo de anotação de traços da iniciativa *metaTraits* (EMBL), eliminando a dependência de submissão manual e tornando o processo escalável e reproduzível.
2. **Separação clara entre comparação e interpretação**: a semelhança entre amostras assenta exclusivamente na composição taxonómica; os traços funcionais são apenas a camada de leitura.
3. **Camada interpretativa comparativa e não-prescritiva**, que traduz indicadores técnicos numa leitura acessível ao produtor, enquadrada como *potencial microbiano inferido* e não como medição direta.

1. Enquadramento e objetivos

1.1. Contexto

A análise do microbioma do solo é hoje um indicador emergente de saúde e funcionalidade do solo agrícola. A sequenciação do gene 16S rRNA permite caracterizar a composição taxonómica da comunidade bacteriana de forma custo-eficiente. Contudo, a composição taxonómica por si só é de difícil interpretação agronómica: importa traduzi-la em **funções** (ciclos de nutrientes, decomposição, promoção de crescimento vegetal, resiliência, entre outras).

O presente projeto operacionaliza o conhecimento entre táxones microbianos e traços fenotípicos num produto utilizável, fechando o ciclo entre **dado bruto de sequenciação e leitura funcional acionável**.

1.2. Objetivos

- Construir uma **base de dados de referência** de perfis funcionais de solo de vinha, a partir de relatórios de sequenciação 16S.

- Desenvolver um **mecanismo de comparação** que posicione uma amostra nova face à base e infira o seu perfil funcional.
- Disponibilizar uma **plataforma web** simples, autónoma e publicável, que sirva de prova de conceito e de evidência do trabalho realizado.
- Definir uma **camada interpretativa** que torne os resultados compreensíveis para um público não-especialista, mantendo rigor e prudência científica.

2. Dados de base

2.1. Amostras de microbioma (input)

A unidade de informação de entrada é o **relatório Bracken** (estilo Kraken2), resultante da classificação taxonómica das leituras de sequenciação 16S. Este relatório contém a hierarquia taxonómica completa (Domínio → Filo → Classe → Ordem → Família → Género → Espécie) com a abundância associada a cada nível.

Decisão metodológica: resolução ao nível de género. A sequenciação do 16S oferece resolução taxonómica fiável tipicamente até ao nível de **género**. Em conformidade, todo o pipeline colapsa a informação de espécie no respetivo género e trabalha exclusivamente a esse nível. Esta opção é deliberada e alinhada com as boas práticas para dados 16S.

A coleção de referência **agrega vários projetos de sequenciação** (repositórios públicos ENA/SRA) e amostras próprias, consolidados num espaço de comparação comum. Cada amostra recebe um **identificador estável** (ver “Identidade e rastreio das amostras”), pelo que a base cresce por simples adição de ficheiros.

Controlo de qualidade: exclusão de amostras degeneradas. Algumas sequenciações falham (cobertura insuficiente), produzindo perfis sem conteúdo informativo — tipicamente colapsados num único género. Estas amostras são identificadas por um **critério objetivo** (≤ 2 géneros detetados, contra ≥ 20 nas válidas) e **excluídas a montante** do pipeline. A exclusão é reversível e auditável: as amostras são movidas para uma pasta arquivada (fora do âmbito de processamento) e registadas num relatório dedicado.

2.2. Base referência de traços funcionais

A anotação funcional assenta numa base de conhecimento derivada do *metaTraits*, organizada **por género**. Para cada género, a base regista, por traço:

- a natureza do traço (discreto/categórico ou numérico);
- o número de observações e de bases de dados que o suportam;
- o **rótulo maioritário** (ex.: presença/ausência de uma função, estado dominante, ou valor numérico mediano com unidade).

Esta base constitui a tabela de consulta a partir da qual cada amostra é enriquecida com o seu perfil funcional ao nível da comunidade.

3. Arquitetura e metodologia

O sistema está organizado num **pipeline file-driven**: a base de dados é, por construção, o conteúdo da pasta de amostras; adicionar, remover ou substituir amostras resume-se a alterar ficheiros e voltar a correr o pipeline, sem intervenção no código.

3.1. Processamento taxonómico e normalização

O relatório Bracken é processado por um analisador que percorre a hierarquia taxonómica, mapeia os níveis canónicos, **colapsa as espécies no género pai** e emite um perfil normalizado de abundâncias relativas por género. Este formato uniforme é a entrada comum de todas as etapas subsequentes.

3.1.1. Identidade e rastreio das amostras

Como a base agrega amostras de origens distintas, cada amostra é identificada pela sua **accession** (identificador único e intrínseco do repositório de sequenciação), e não por uma numeração manual sujeita a colisões entre projetos. O pipeline mantém um **registo persistente** que atribui a cada accession um **número estável**: amostras novas recebem automaticamente o próximo número ao serem adicionadas, e as existentes mantêm o seu para sempre. Este registo é a tabela de correspondência número ↔ amostra, garantindo rastreabilidade e tornando a expansão da base robusta e à prova de erro (basta colocar os ficheiros na pasta).

3.2. Anotação de traços — reprodução local do *sumTraits*

O fluxo oficial do *metaTraits* (*sumTraits*) exigiria submissão manual de cada amostra, inviabilizando o processamento em lote. Foi desenvolvida e **validada uma reprodução local e offline** desse fluxo, que:

- enriquece cada táxon do perfil com os respetivos traços;
- **agrega ao nível da comunidade**, ponderando pela abundância de cada género;
- replica fielmente o formato de saída do sistema de referência.

A agregação respeita a natureza de cada traço:

- **Traços booleanos** → fração da comunidade com a função (consenso verdadeiro/falso e ausência de maioria).
- **Traços categóricos** → estado dominante por abundância e respetivas alternativas.
- **Traços numéricos** → média ponderada pela abundância (ex.: pH ótimo de crescimento, salinidade ótima, temperatura ótima).

Um **invariante de consistência** é usado como teste de regressão: para cada traço discreto, as categorias somam a totalidade da abundância da comunidade.

3.3. Matriz de composição

A partir dos perfis normalizados de todas as amostras válidas, é consolidada uma **matriz de composição** (gêneros × amostras) de abundâncias relativas. Esta matriz é o espaço onde se mede a semelhança entre amostras.

3.4. Diversidade beta e ordenação

A proximidade entre amostras é quantificada por **distância de Bray-Curtis** sobre a composição taxonômica. O conjunto de distâncias é resumido por **Análise de Coordenadas Principais (PCoA)**, que projeta as amostras num espaço de baixa dimensão para visualização e posicionamento.

Para posicionar uma **amostra nova** no mesmo espaço sem recalculá-la toda a ordenação, foi implementada uma **projeção fora-da-amostra** (fórmula de Gower). Esta projeção utiliza as distâncias da amostra nova a **toda** a coleção de referência, garantindo um posicionamento geométrico fiel — incluindo a detecção de amostras atípicas — independente do número de vizinhos considerados na inferência do perfil.

3.5. Comparação e inferência do perfil funcional

O mecanismo de inferência separa rigorosamente dois espaços:

1. **Espaço de comparação — composição taxonômica.** A amostra nova é comparada às amostras de referência por distância de Bray-Curtis; identificam-se as amostras mais semelhantes.
2. **Tabela de consulta — perfil funcional.** Os traços das amostras de referência mais semelhantes são **importados** para a amostra nova, constituindo o seu perfil funcional inferido.

Os traços **nunca** entram no cálculo da semelhança. Esta separação é uma garantia metodológica: a leitura funcional é uma consequência da proximidade composicional, não um fator circular dessa proximidade. O utilizador pode optar por importar o perfil da amostra mais semelhante ou combinar várias amostras de referência por média ponderada pela semelhança.

4. Camada interpretativa

A camada interpretativa transforma o perfil funcional técnico numa leitura legível, dirigida simultaneamente ao produtor e ao técnico (registo em camadas: linguagem corrente com o termo técnico em detalhe).

4.1. Princípios

- **Natureza do dado.** Os indicadores representam *potencial* funcional inferido da composição da comunidade — **não** uma medição química ou de atividade do solo. Este enquadramento é apresentado de forma permanente e inequívoca.

- **Leitura comparativa.** Os rótulos *baixo / moderado / alto* são **relativos à coleção de referência** (percentis calculados dinamicamente), não limiares absolutos. “Alto” significa acima do habitual em parcelas semelhantes.
- **Descreve, não recomenda.** A ferramenta descreve o estado microbiano; não emite recomendações agronômicas nem linguagem prescritiva.
- **Seleção criteriosa de traços.** De várias milhares de variáveis da base de referência, retêm-se apenas os traços com relevância agronômica reconhecida; os restantes são excluídos na fase de processamento.

4.2. Estrutura de grupos funcionais

Os traços são organizados em **grupos funcionais** fundamentados na literatura de indicadores microbianos de saúde do solo, designadamente: ciclo do azoto (fixação, nitrificação, desnitrificação, amonificação), arejamento do solo, decomposição (matéria vegetal, proteica, compostos recalcitrantes e geral), ciclo do enxofre, metilotrofia/metanotrofia, redox de ferro e manganês, mobilização de fósforo, promoção de crescimento vegetal, fixação autotrófica de carbono, resistência a stress e agregação/estruturação do solo.

4.3. Régua relativas e escalas absolutas

A maioria dos grupos usa **régua relativa** (percentis da coleção). Os **ótimos ambientais da comunidade** (pH, temperatura e salinidade) merecem tratamento distinto:

- **pH e temperatura** usam **escalas absolutas** de significado universal (escala de pH; classes microbiológicas de temperatura), por serem robustas e interpretáveis isoladamente.
- **Salinidade** é apresentada com **régua relativa** à coleção, mantendo embora visível o **valor absoluto** (em % NaCl), por se ter verificado que a escala absoluta de halofilia não discrimina adequadamente solos de vinha (todos pouco salinos).

4.4. Exemplos de leitura

O enquadramento permanente apresentado ao utilizador é:

Indicadores do potencial microbiano do solo, inferidos da composição da comunidade. Leitura comparativa, não medição.

A linguagem é simultaneamente acessível e técnica: a frase corrente integra o termo especializado, dispensando um seletor de modo. Exemplos efetivos de frases de síntese (parametrizadas pelo nível relativo à coleção):

Grupo funcional	Nível	Frase apresentada
-----------------	-------	-------------------

Fixação de azoto	Alto	“Mais microrganismos do que o habitual capazes de captar azoto do ar (potencial de fixação de azoto elevado).”
Mobilização de fósforo	Alto	“Capacidade de disponibilizar fósforo acima do habitual — mineralização ativa de fósforo do solo.”
Arejamento do solo	Baixo	“Circulação de ar abaixo do habitual — compatível com solo mais compactado ou húmido.”
Decomposição — fibra vegetal	Baixo	“Capacidade de decompor fibra vegetal abaixo do habitual.” (com nota: processo realizado sobretudo por fungos, não captados por este método).

Cada grupo dispõe de três variantes (baixo / moderado / alto), selecionadas em função do percentil da amostra face à coleção de referência.

5. Plataforma

5.1. Descrição funcional

A plataforma é uma **aplicação web de página única**, sem necessidade de servidor ou de base de dados em tempo de execução: todos os dados de referência são pré-calculados e embebidos como ficheiros estáticos. Antes de qualquer análise, um **cartão de base de dados de referência** resume, de forma sempre visível e derivada dos próprios dados, a dimensão da coleção (amostras, géneros, indicadores funcionais e grupos), enquadrando a leitura. O fluxo de utilização é:

1. O utilizador carrega um relatório de sequenciação (Bracken) de uma amostra nova — ou aciona uma amostra de exemplo — e pode, **opcionalmente**, preencher um **formulário de metadados agronómicos** (identificação da parcela, região, cultura, casta, data de colheita, tipo de solo, modo de produção, coberto vegetal, rega, fertilização recente e observações). Estes metadados são facultativos e **não influenciam a análise**: servem para identificar a amostra no relatório e nos ficheiros exportados.
2. A amostra é comparada à coleção de referência; identificam-se as amostras mais semelhantes.
3. Importa-se o perfil funcional e apresenta-se:
 - a **identificação da amostra** (quando preenchidos os metadados);
 - um **resumo** de indicadores-chave (géneros detetados, diversidade da comunidade, indicadores funcionais, ótimos ambientais);
 - a **leitura interpretativa por grupos**, com frases parametrizadas pelo nível relativo;
 - **tabelas técnicas** detalhadas (traços funcionais e ótimos ambientais);
 - um **gráfico de ordenação** (PCoA) com a posição da amostra nova e a tabela das amostras de referência mais próximas.

4. O resultado pode ser **exportado em dois formatos**, ambos gerados no navegador:
 - **PDF institucional** — relatório formatado com capa identificativa, sumário executivo, identificação e metadados da amostra, metodologia e enquadramento de financiamento (PRR / NextGenerationEU);
 - **JSON estruturado** — ficheiro de dados com os metadados, a metodologia, as amostras de referência usadas, a diversidade, os ótimos ambientais, os indicadores funcionais e as ressalvas interpretativas, para arquivo ou integração posterior.

A interface está integralmente em **português de Portugal** e foi concebida para ser **publicável** em serviços de alojamento estático (ex.: GitHub Pages, Netlify), servindo de evidência demonstrável.

5.2. Características técnicas

- Arquitetura **estática** (HTML/CSS/JavaScript), sem dependências de backend.
- Cálculos de comparação, projeção e classificação executados **no navegador**.
- Dados de referência gerados pelo pipeline e versionados com a aplicação.
- Metadados da amostra e ficheiros exportados (PDF e JSON) processados **integralmente no cliente**, sem persistência em servidor — a aplicação não armazena dados do utilizador.
- Concebida para **portabilidade e reprodutibilidade** (sem estado externo).

6. Validação e controlo de qualidade

O sistema foi sujeito a verificações em vários pontos do pipeline:

- **Anotação de traços.** O invariante de consistência (soma das categorias = 1 por traço discreto) é verificado como teste de regressão.
- **Projeção de amostra nova.** A projeção fora-da-amostra foi validada reproduzindo as coordenadas de referência de amostras conhecidas, com erro numérico desprezável. Uma amostra idêntica a uma da coleção projeta-se sobre a sua posição esperada.
- **Cadeia ponta-a-ponta.** A amostra de exemplo foi processada por toda a cadeia (análise do relatório → vetor de composição → distâncias → projeção → perfil), confirmando coerência entre a amostra mais semelhante identificada e a sua posição na ordenação.
- **Régua relativa.** A classificação por percentis foi verificada quanto à distribuição esperada na coleção.
- **Controlo de qualidade da coleção.** As amostras degeneradas foram detetadas pelo critério objetivo (≤ 2 géneros) e excluídas. A sua remoção foi validada pelo efeito na ordenação: estas amostras formavam um aglomerado artificial que dominava o primeiro eixo da PCoA; após exclusão, a variância explicada por esse

eixo desceu substancialmente, confirmando que se tratava de um artefacto técnico e não de variação biológica.

- **Revisão do pipeline.** A cadeia foi revista de ponta a ponta (código, consistência entre etapas, coerência da apresentação), confirmando o alinhamento de identificadores entre todos os artefactos e a reconciliação do conjunto de traços apresentados com as respectivas traduções.

8. Conclusão

O trabalho realizado materializa um sistema completo e coerente que vai do dado bruto de sequenciação à leitura funcional interpretável, suportado por decisões metodológicas explícitas e auditáveis. A reprodução local do fluxo de anotação, a separação rigorosa entre comparação e interpretação, e o enquadramento prudente e não-prescritivo da camada de leitura constituem os pilares de qualidade do entregável. A plataforma resultante é autónoma, reproduzível e publicável, cumprindo o objetivo de servir simultaneamente como prova de conceito e como evidência do trabalho desenvolvido.

Anexo A — Indicadores quantitativos do piloto

Os valores seguintes caracterizam o estado do piloto à data indicada. Trata-se de uma fotografia pontual: a base de referência é incremental, pelo que as contagens e as métricas dependentes da coleção evoluem com a adição de novas amostras.

A.1. Base de dados de referência

Indicador	Valor
Amostras na coleção de referência ativa	1 138
Amostra reservada como exemplo da plataforma (fora da coleção)	1
Amostras excluídas (controlo de qualidade)	235
Projetos de sequenciação de origem	múltiplos (ENA/SRA) + amostras próprias
Géneros distintos na matriz de composição	2 660
Indicadores funcionais apresentados na plataforma	357 (selecionados de mais de 2 600 traços da base de referência)
Grupos funcionais interpretativos	17 grupos/subgrupos + ótimos ambientais (pH, temperatura, salinidade)

Critério de exclusão (controlo de qualidade). As amostras degeneradas apresentam ≤ 2 géneros detetados; as amostras válidas apresentam ≥ 20 géneros. A separação entre os dois conjuntos é limpa, sem zona de sobreposição.

A.2. Diversidade beta e ordenação

Indicador	Valor
Métrica de distância	Bray-Curtis (sobre composição de género)
Método de ordenação	Análise de Coordenadas Principais (PCoA)
Variância explicada — eixo PC1	16,7 %
Variância explicada — eixo PC2	8,1 %
Variância acumulada (PC1 + PC2)	24,8 %

A.3. Validação numérica

Verificação	Resultado
Projeção de amostra nova (reprodução das coordenadas de amostras conhecidas)	erro numérico $\approx 5 \times 10^{-7}$
Inferência sobre amostra reservada (exemplo <i>held-out</i> , fora da coleção)	vizinho mais próximo a Bray-Curtis $\approx 0,40$
Régua relativa (distribuição por terços na coleção)	conforme o esperado
Invariante de consistência da agregação (soma das categorias por traço discreto)	= 1,0
Efeito da exclusão de degeneradas na ordenação (variância do PC1)	32,3 % $\rightarrow$ 16,7 % (artefacto removido)